

§ 3 矩阵分析及其应用

- 一、向量范数和矩阵范数
- 二、矩阵序列与矩阵级数
- 三、方阵函数及其计算

§ 3.1 向量范数(Vector Norm)

一、向量范数的概念

考虑数域 F 上的线性空间 $V(F)$.

定义 若 $V(F)$ 上的实值映射 $\|\cdot\|: \alpha \mapsto \|\alpha\|$ 满足

1. 正定性: $\|\alpha\| \geq 0$ 且 $\|\alpha\| = 0 \Leftrightarrow \alpha = 0$;

2. 齐次性: $\|k\alpha\| = |k| \|\alpha\|$, $\forall k \in F, \alpha \in V$;

3. 三角不等式: $\|\alpha \pm \beta\| \leq \|\alpha\| + \|\beta\|$,

则称 $\|\cdot\|$ 为 $V(F)$ 的一个**范数**,

称 $(V(F); \|\cdot\|)$ 为**赋范线性空间** (Normed Space).

注 内积空间 $(V^n(F); (\cdot, \cdot))$ 都可定义范数

$$\|\alpha\| = \sqrt{(\alpha, \alpha)}, \quad \forall \alpha \in V^n(F),$$

称为由该内积诱导的范数或与内积 (\cdot, \cdot) **相容** 的范数. 2

§ 3.1 向量范数(Vector Norm)

一、向量范数的概念

例 C^n 上的 p -范数

对任意 $p \in (0, \infty)$, C^n 上的 p -范数定义为

$$\|X\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}, \quad \forall X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in C^n.$$

Examples

$$\|X\|_1 = \sum_{i=1}^n |x_i|; \quad \|X\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}} = \sqrt{(X, X)};$$

$$\|X\|_\infty = \max_{i=1,2,\dots,n} |x_i|.$$

§ 3.1 向量范数(Vector Norm)

例 计算向量 $X = (1 \ -2 \ 3)^T$ 的各种范数

解: $\|X\|_1 = |1| + |-2| + |3| = 6$

$$\|X\|_\infty = \max(|1|, |-2|, |3|) = 3$$

$$\|X\|_2 = \sqrt{1^2 + (-2)^2 + 3^2} = \sqrt{14}$$

$$\|X\|_1 = \sum_{i=1}^n |x_i|; \|X\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}}; \|X\|_\infty = \max_{i=1,2,\dots,n} |x_i|$$

§ 3.1 向量范数(Vector Norm)

例 设 $x \in R^n$ (或 $x \in C^n$), 则 $\|x\|_1, \|x\|_2, \|x\|_\infty$ 是 R^n 上 (或 C^n 上) 的向量范数。

Cauchy不等式: $(\sum_{i=1}^n x_i y_i)^2 \leq \sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i^2$

证明: 只验证三角不等式, 以“2”范数为例.

即对 $\forall x, y \in R^n$, 有 $\|x + y\|_2 \leq \|x\|_2 + \|y\|_2$.

事实上, $\|x + y\|_2^2 = (x + y, x + y) = (x, x) + (y, y) + 2(x, y)$

由柯西不等式 $|(x, y)| \leq \|x\|_2 \cdot \|y\|_2$, 则

$$\begin{aligned}\|x + y\|_2^2 &\leq \|x\|_2^2 + 2\|x\|_2\|y\|_2 + \|y\|_2^2 = (\|x\|_2 + \|y\|_2)^2 \\ &\Rightarrow \|x + y\|_2 \leq \|x\|_2 + \|y\|_2. \blacksquare\end{aligned}$$

注: 证“1”范数时, 用 $\sum_{i=1}^n |x_i + y_i| \leq \sum_{i=1}^n |x_i| + \sum_{i=1}^n |y_i|$. 5

§ 3.1 向量范数(Vector Norm)

一、向量范数的概念

例 向量的坐标范数

设 $V^n(F) = \text{Span}\{\alpha_1, \alpha_2, \dots, \alpha_n\}, \forall \alpha \in V^n(F),$

$$\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)X, \quad X \in F^n.$$

则可通过坐标空间 F^n 上的范数定义 $V^n(F)$ 上的范数:

$$\|\alpha\| \triangleq \|X\|_{F^n}.$$

Example

$$\|\alpha\| \triangleq \|X\|_1 = \sum_{i=1}^n |x_i|, \quad \forall \alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)X.$$

§ 3.1 向量范数(Vector Norm)

一、向量范数的概念


用范数可以刻画两向量间的距离: $d(\alpha, \beta) = \|\alpha - \beta\|$.

邻域(Neighborhood)


$$N(\alpha_0, r) = \{\alpha \in V^n(F) : d(\alpha, \alpha_0) < r\}, \quad \alpha_0 \in V^n(F), r > 0.$$

Examples


p -范数下, R^2 中的“单位球” $N(0,1)$:



$p = 1$



$p = 2$



$p = \infty$

§ 3.1 向量范数(Vector Norm)

一、向量范数的概念


用范数可以刻画两向量间的距离: $d(\alpha, \beta) = \|\alpha - \beta\|$.

邻域(Neighborhood)

$$N(\alpha_0, r) = \{\alpha \in V^n(F) : d(\alpha, \alpha_0) < r\}, \quad \alpha_0 \in V^n(F), r > 0.$$

Examples

p -范数下, R^2 中的“单位球” $N(0,1)$:



§ 3.1 向量范数(Vector Norm)

二、向量序列的极限

用范数可以刻画两向量间的距离: $d(\alpha, \beta) = \|\alpha - \beta\|$.

定义 设有向量序列 $\{\alpha^{(k)}: k = 1, 2, \dots\} \subseteq (V^n(F), \|\cdot\|)$.
若存在某 $\beta \in V^n(F)$, 使得

$$\|\alpha^{(k)} - \beta\| \rightarrow 0, \text{ 当 } k \rightarrow \infty,$$

则称向量序列 $\{\alpha^{(k)}: k = 1, 2, \dots\}$ 依范数收敛于 β .
 β 称为该序列的极限, 记 $\alpha^{(k)} \xrightarrow{\|\cdot\|} \beta$.

§ 3.1 向量范数(Vector Norm)

二、向量序列的极限

Example

取 $\alpha^{(k)} = \left(\frac{1}{k}, \frac{1}{k+1} + 1, \frac{1}{k+2} + 2\right)^T \in R^3$, $\beta = (0,1,2)^T$, 则

$$\|\alpha^{(k)} - \beta\|_1 = \frac{1}{k} + \frac{1}{k+1} + \frac{1}{k+2} \rightarrow 0,$$

故 $\alpha^{(k)} \xrightarrow{\|\cdot\|_1} \beta$. ■

§ 3.1 向量范数(Vector Norm)

三、向量范数的连续性与等价性

定义 称 $(V^n(F), \|\cdot\|)$ 上的向量函数(映射, 泛函) $f: V^n(F) \rightarrow R$
(补) 是连续的, 如果

$$\alpha^{(k)} \xrightarrow{\|\cdot\|} \beta \implies f(\alpha^{(k)}) \xrightarrow{|\cdot|} f(\beta).$$

引理 $V^n(F)$ 上的任意范数 $\|\cdot\|$ 是连续函数:

$$\alpha^{(k)} \xrightarrow{\|\cdot\|} \beta \implies \|\alpha^{(k)}\| \xrightarrow{|\cdot|} \|\beta\|.$$

证明

$$|\|\alpha^{(k)}\| - \|\beta\|| \leq \|\alpha^{(k)} - \beta\| \rightarrow 0. \quad \blacksquare$$

§ 3.1 向量范数(Vector Norm)

三、向量范数的连续性与等价性

定义 设 $\|\cdot\|^{(1)}, \|\cdot\|^{(2)}$ 是 $V^n(F)$ 上的两种范数. 如果存在正数 c_1, c_2 , 使得

$$c_1 \|\alpha\|^{(2)} \leq \|\alpha\|^{(1)} \leq c_2 \|\alpha\|^{(2)}, \quad \forall \alpha \in V^n(F),$$

则称这两个范数是**等价**的.

含义: $\|\alpha^{(k)} - \beta\|^{(1)} \rightarrow 0 \Leftrightarrow \|\alpha^{(k)} - \beta\|^{(2)} \rightarrow 0.$

定理 有限维空间 $V^n(F)$ 上的任意两范数都是等价的.

§ 3.1 向量范数(Vector Norm)

三、向量范数的连续性与等价性

定理 $\forall x, y \in R^n$, 有

$$(1) \|x\|_{\infty} \leq \|x\|_2 \leq \sqrt{n} \|x\|_{\infty}$$

$$(2) \|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2$$

注: R^n 上一切范数都等价

$$(3) \|x\|_{\infty} \leq \|x\|_1 \leq n \|x\|_{\infty}$$

证明 (1)

记 $x = (x_1, \dots, x_n)^T$, $\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i| \equiv |x_j|$,

于是有:

$$(a) \|x\|_{\infty}^2 = |x_j|^2 \leq \sum_{i=1}^n |x_i|^2 = \|x\|_2^2 \Rightarrow \|x\|_{\infty} \leq \|x\|_2$$

$$(b) \|x\|_2^2 = \sum_{i=1}^n |x_i|^2 \leq \sum_{i=1}^n |x_j|^2 = n |x_j|^2 = n \|x\|_{\infty}^2$$

$$\Rightarrow \|x\|_2 \leq \sqrt{n} \|x\|_{\infty} \blacksquare$$

§ 3.1 向量范数(Vector Norm)

定理 $\lim_{k \rightarrow \infty} X^{(k)} = X^* \Leftrightarrow \|X^{(k)} - X^*\| \rightarrow 0 \ (k \rightarrow \infty)$

证 显然, $\lim_{k \rightarrow \infty} X^{(k)} = X^* \Leftrightarrow \|X^{(k)} - X^*\|_{\infty} \rightarrow 0 \ (k \rightarrow \infty)$

而对于 R^n 上任一种范数 $\|\bullet\|$, 由范数的等价性,

存在常数 $C_1, C_2 > 0$ 使

$$C_1 \|X^{(k)} - X^*\|_{\infty} \leq \|X^{(k)} - X^*\| \leq C_2 \|X^{(k)} - X^*\|_{\infty}$$

于是有

$$\|X^{(k)} - X^*\|_{\infty} \rightarrow 0 \Leftrightarrow \|X^{(k)} - X^*\| \rightarrow 0 \ (k \rightarrow \infty) \quad \blacksquare$$



三、向量范数的连续性与等价性

推论 设 $V^n(F) = \text{Span}\{\alpha_1, \alpha_2, \dots, \alpha_n\}$, 向量序列有坐标表示 $\alpha^{(k)} = (\alpha_1, \alpha_2, \dots, \alpha_n)X^{(k)}$, $\beta = (\alpha_1, \alpha_2, \dots, \alpha_n)Y$. 则

坐标收敛
Tips: 坐标范数是向量范数的一种
向量收敛

$$\|X^{(k)} - Y\|_{F^n} \rightarrow 0 \iff \|\alpha^{(k)} - \beta\|_{V^n(F)} \rightarrow 0$$

范数等价

范数是坐标的连续函数(定理)

范数的连续性

$$\|\alpha^{(k)}\|_{V^n(F)} \rightarrow \|\beta\|_{V^n(F)}$$

$$\|X^{(k)} - Y\|_{\infty} \rightarrow 0$$

定理

\iff 依分量收敛: $x_i^{(k)} \rightarrow y_i$,

其中, $X^{(k)} = \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{bmatrix}, Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}.$



§ 3. 1. 2 矩阵范数

(Matrix Norm)

§ 3.1 矩阵范数

一、矩阵范数的概念

定义

若 $F^{n \times n}$ 上的实值映射 $\|\cdot\|: A \mapsto \|A\|$ 满足

1. 非负性: $\|A\| \geq 0$ 且 $\|A\| = 0 \Leftrightarrow A = 0$;
2. 齐次性: $\|kA\| = |k| \|A\|$, $\forall k \in F, A \in F^{m \times n}$;
3. 三角不等式: $\|A \pm B\| \leq \|A\| + \|B\|$;
4. 相容性: $\|AB\| \leq \|A\| \|B\|$,

则称 $\|\cdot\|$ 为一个矩阵范数.

由于矩阵有乘法运算, 故在定义矩阵范数时需考虑与乘法运算的相容性.

例

$C^{n \times n}$ 上 $\|A\| = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|$ 是矩阵范数.

§ 3.1 矩阵范数

一、矩阵范数的概念

定义

若 $F^{n \times n}$ 上的实值映射 $\|\cdot\|: A \mapsto \|A\|$ 满足

1. 非负性: $\|A\| \geq 0$ 且 $\|A\| = 0 \Leftrightarrow A = 0$;
 2. 齐次性: $\|kA\| = |k| \|A\|$, $\forall k \in F, A \in F^{m \times n}$;
 3. 三角不等式: $\|A \pm B\| \leq \|A\| + \|B\|$;
 4. 相容性: $\|AB\| \leq \|A\| \|B\|$,
- 则称 $\|\cdot\|$ 为一个矩阵范数.

例: 定义 $\|A\| = \max_{1 \leq i, j \leq n} |a_{ij}|$ 不满足相容性.

如: $A = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$, $AB = \begin{pmatrix} 4 & 4 \\ 4 & 4 \end{pmatrix}$,

$$\|AB\| = 4, \quad \|A\| \cdot \|B\| = 2 \times 1 = 2$$

§ 3.1 矩阵范数

例5 $C^{n \times n}$ 上的 **Frobenius 范数**:

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = [\text{tr}(A^H A)]^{\frac{1}{2}}.$$

证明 只证相容性 $\|AB\|_F \leq \|A\|_F \|B\|_F$.

$$\begin{aligned} \|AB\|_F^2 &= \sum_{i=1}^n \sum_{j=1}^n \left| \sum_k a_{ik} b_{kj} \right|^2 \\ &\leq \sum_{i=1}^n \sum_{j=1}^n \left[\left(\sum_k |a_{ik}|^2 \right) \left(\sum_k |b_{kj}|^2 \right) \right] \\ &= \sum_{i=1}^n \left[\sum_k |a_{ik}|^2 \left(\sum_{j=1}^n \sum_{k=1}^n |b_{kj}|^2 \right) \right] \\ &= \left(\sum_{i=1}^n \sum_{k=1}^n |a_{ik}|^2 \right) \left(\sum_{j=1}^n \sum_{k=1}^n |b_{kj}|^2 \right) \\ &= \|A\|_F^2 \|B\|_F^2. \quad \blacksquare \end{aligned}$$

Hölder inequality, or
Cauchy-Schwartz inequality

§ 3.1 矩阵范数

例5 $C^{n \times n}$ 上的 **Frobenius 范数**:

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = [\operatorname{tr}(A^H A)]^{\frac{1}{2}}.$$

例6 设 $A \in C^{n \times n}$ 的奇异值为 $\sigma_1, \sigma_2, \dots, \sigma_r$, 则

$$\|A\|_F^2 = \sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2.$$

证明 因为 $A^H A$ 的所有非零特征值为 $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$, 故

$$\operatorname{tr}(A^H A) = \sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2 = \|A\|_F^2. \quad \blacksquare$$

§ 3.1 矩阵范数

二、诱导范数

定义

称 $F^{n \times n}$ 上的矩阵范数 $\|\cdot\|_*$ 和 F^n 上的向量范数 $\|\cdot\|$ 是相容的或协调的, 如果

$$\|Ax\| \leq \|A\|_* \cdot \|x\|, \quad \forall A \in F^{n \times n}, x \in F^n.$$

§ 3.1 矩阵范数

二、诱导范数

Example

矩阵 F -范数与向量 2-范数是**相容的**: 令 $Ax = y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$,

$$\begin{aligned} \|Ax\|_2^2 &= \sum_{i=1, \dots, n} |y_i|^2 = \sum_{i=1, \dots, n} \left| \sum_{k=1, \dots, n} a_{ik} x_k \right|^2 \\ &\leq \sum_{i=1, \dots, n} \left(\sum_{k=1, \dots, n} |a_{ik}|^2 \sum_{k=1, \dots, n} |x_k|^2 \right) \\ &= \|A\|_F^2 \|x\|_2^2. \quad \blacksquare \end{aligned}$$

Hölder inequality, or
Cauchy-Schwartz inequality

§ 3.1 矩阵范数

二、诱导范数

定理 设 $\|\cdot\|$ 是 F^n 上的向量范数, 则 $F^{n \times n}$ 上的矩阵范数

$$\|A\|_* = \max_{x \neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\}$$

与 $\|\cdot\|$ 相容, 称为由 $\|\cdot\|$ 诱导的矩阵范数或算子范数.

证明 正定性和齐次性显然. 下证三角不等式.

$$\begin{aligned} \|A + B\|_* &= \max_{x \neq 0} \left\{ \frac{\|(A + B)x\|}{\|x\|} \right\} \leq \max_{x \neq 0} \left\{ \frac{\|Ax\| + \|Bx\|}{\|x\|} \right\} \\ &\leq \max_{x \neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\} + \max_{x \neq 0} \left\{ \frac{\|Bx\|}{\|x\|} \right\} \\ &= \|A\|_* + \|B\|_*. \quad \blacksquare \end{aligned}$$



定理

设 $\|\cdot\|$ 是 F^n 上的向量范数, 则 $F^{n \times n}$ 上的矩阵范数

$$\|A\|_* = \max_{x \neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\}$$

与 $\|\cdot\|$ 相容, 称为由 $\|\cdot\|$ 诱导的矩阵范数或算子范数.

证明

矩阵范数的相容性 $\|AB\|_* \leq \|A\|_* \cdot \|B\|_*$:

(续)

$$\|AB\|_* = \max_{\substack{x \neq 0 \\ Bx \neq 0}} \left\{ \frac{\|ABx\|}{\|x\|} \right\}$$

$$= \max_{Bx \neq 0} \left\{ \frac{\|ABx\|}{\|Bx\|} \cdot \frac{\|Bx\|}{\|x\|} \right\}$$

$$\leq \max_{Bx \neq 0} \left\{ \frac{\|ABx\|}{\|Bx\|} \right\} \cdot \max_{Bx \neq 0} \left\{ \frac{\|Bx\|}{\|x\|} \right\}$$

$$\leq \max_{x \neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\} \cdot \max_{x \neq 0} \left\{ \frac{\|Bx\|}{\|x\|} \right\} = \|A\|_* \cdot \|B\|_* \quad \blacksquare$$

$$\{x | Bx \neq 0\} \subseteq \{x | x \neq 0\}$$



定理

设 $\|\cdot\|$ 是 F^n 上的向量范数, 则 $F^{n \times n}$ 上的矩阵范数

$$\|A\|_* = \max_{x \neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\}$$

与 $\|\cdot\|$ 相容, 称为由 $\|\cdot\|$ 诱导的矩阵范数.

证明 (续)

下证与向量范数的相容性 $\|Ax\| \leq \|A\|_* \cdot \|x\|$:

$x = 0$ 时, 显然成立.

$$x \neq 0 \text{ 时, } \|A\|_* = \max_{y \neq 0} \left\{ \frac{\|Ay\|}{\|y\|} \right\} \geq \frac{\|Ax\|}{\|x\|},$$

从而, $\|Ax\| \leq \|A\|_* \cdot \|x\|$. ■



说明：矩阵的算子范数是矩阵范数，矩阵范数不一定是算子范数。

例：弗罗贝尔乌斯（*Frobenius*）范数不是诱导范数。

这是因为单位矩阵 I 的任何诱导范数都是1，

$$\forall x \neq 0, \frac{\|Ix\|_v}{\|x\|_v} = \frac{\|x\|_v}{\|x\|_v} = 1, \text{ 而 } \|I\|_F = \sqrt{\sum_{i=1}^n 1^2} = \sqrt{n} \neq 1。$$

2、以后讨论范数都是诱导范数，均是相容的，

且与它相应的向量范数也是相容的。

§ 3.1 矩阵范数的概念

二、诱导范数

例 p -范数诱导的矩阵范数 (注意与向量 p -范数的区别)

$$\|A\|_1 = \max_j \left\{ \sum_{i=1}^n |a_{ij}| \right\}$$

最大列和范数

$$\|A\|_\infty = \max_i \left\{ \sum_{j=1}^n |a_{ij}| \right\}$$

最大行和范数

谱范数

$$\|A\|_2 = \sqrt{\lambda_{\max}} = \sigma_1 \quad (\lambda_{\max} \text{ 是 } A^H A \text{ 的最大特征值})$$

Examples

$$1. \text{ 对 } A = \begin{bmatrix} -2 & 0 & 2+i \\ 2 & 5 & 0 \\ 1 & 2 & -1 \end{bmatrix}, \quad \|A\|_1 = \max \{5, 7, \sqrt{5} + 1\} = 7.$$

§ 3.1 矩阵范数的概念

二、诱导范数

例 p -范数诱导的矩阵范数 (注意与向量 p -范数的区别)

$$\|A\|_1 = \max_j \left\{ \sum_{i=1}^n |a_{ij}| \right\}$$

最大列和范数

$$\|A\|_\infty = \max_i \left\{ \sum_{j=1}^n |a_{ij}| \right\}$$

最大行和范数

谱范数

$$\|A\|_2 = \sqrt{\lambda_{\max}} = \sigma_1 \quad (\lambda_{\max} \text{ 是 } A^H A \text{ 的最大特征值})$$

矩阵范数公式： 每个向量范数，都可相应地定义一个矩阵范数，常用的矩阵范数的计算公式由上给出。



$$(1) \|A\|_{\infty} = \max_{x \neq 0} \frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

证明: (1) 设 $x = (x_1, \dots, x_n)^T$, $\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i| = t$,

$$\mu = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \sum_{j=1}^n |a_{i_0 j}| \text{ (其中 } 1 \leq i_0 \leq n \text{)},$$

于是

$$\|Ax\|_{\infty} = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| |x_j| \leq t \max_i \sum_{j=1}^n |a_{ij}| = t\mu$$

对任何向量 $x \neq 0$, 则有

$$\frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} \leq \mu = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

如果能找到一向量 x_0 , 且 $\|x_0\|_{\infty} = 1$,

使 $\frac{\|Ax_0\|_{\infty}}{\|x_0\|_{\infty}} = \mu$, 那么, 定理得证。



$$(1) \|A\|_{\infty} = \max_{x \neq 0} \frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

证明:

下面来寻求 x_0 , 使比值等于 μ . 记 $x_0 = (x_1, \dots, x_n)^T$, 且使 $\|x_0\|_{\infty} = 1$,

于是

$$Ax_0 = \left(\sum_{j=1}^n a_{1j}x_j, \dots, \sum_{j=1}^n a_{i_0j}x_j, \dots, \sum_{j=1}^n a_{nj}x_j \right)^T,$$

则有:

$$\|Ax_0\|_{\infty} \leq \mu,$$

由此, 应选取 x_0 为 $x_j = \begin{cases} 1, & \text{当 } a_{i_0j} \geq 0 \\ -1, & \text{当 } a_{i_0j} < 0 \end{cases}$, 则 $\|x_0\|_{\infty} = 1$,

及

$$\sum_{j=1}^n a_{i_0j}x_j = \sum_{j=1}^n |a_{i_0j}| = \mu \quad \text{或} \quad \|Ax_0\|_{\infty} = \mu,$$

故: $\max_{x \neq 0} \frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} = \mu$ 。 ■



(2) 证明与 (1) 相似。

(3) $\|A\|_2 = \sqrt{\lambda_{\max}} = \sigma_1$ (λ_{\max} 是 $A^H A$ 的最大特征值)

证明: $\forall A \in R^{n \times n}$, $(A^T A)^T = A^T A$, $A^T A$ 是实对称矩阵, $\forall x \neq 0$,

$$x^T (A^T A) x = (Ax)^T (Ax) = \|Ax\|_2^2 \geq 0, \text{ 因此 } A^T A \text{ 是半正定的,}$$

则 $A^T A$ 特征值大于等于 0。

特征向量两两正交, 设 $u_1, u_2 \cdots u_n$ 是特征根 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 所对应的特征向量,

且 $u_1, u_2 \cdots u_n$ 构成 n 维线性空间中一组正交基, $(u_i, u_j) = \delta_{ij}$

即 $A^T A u_i = \lambda_i u_i (i = 1, 2, \cdots, n)$,

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sqrt{\lambda_{\max}(A^T A)}. \quad \blacksquare$$

§ 3.1 矩阵范数

三、谱半径

谱半径/* spectral radius */:

设 $A \in R^{n \times n}$ 的特征值为 $\lambda_i (i = 1, \dots, n)$

称 $\rho(A) \equiv \max_{1 \leq i \leq n} |\lambda_i|$ 为 A 的谱半径。

四、特征值界

定理(1) 设 $A \in R^{n \times n}$, 则 $\rho(A) \leq \|A\|$,

其中 $\|A\|$ 为满足矩阵、向量相容性条件的矩阵范数（算子范数）。

证明 (1) 设 λ 为 A 的任一特征值, 于是, 存在 $x \neq 0$,

使 $Ax = \lambda x$, 且 $|\lambda| \|x\| = \|\lambda x\| = \|Ax\| \leq \|A\| \cdot \|x\|$,

即 $|\lambda| \leq \|A\|$, 所以 $\rho(A) \leq \|A\|$ 。■

§ 3.1 矩阵范数

三、特征值界 $\rho(A) \equiv \max_{1 \leq i \leq n} |\lambda_i|$

定理(2)： 设 $A \in R^{n \times n}$ 为对称矩阵，则 $\|A\|_2 = \rho(A)$ 。

证明(2)： 若 λ 为 A 的特征值，则 λ^2 为 A^2 的特征根，

又 A 为对称矩阵，则 $A^T A = A^2$ ，且 $A^T A$ 也是对称的，

设 $\rho(A) \leq |\lambda_0|$ ，

则 λ_0 是实数， λ_0^2 必是 A^2 最大特征根，

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_{\max}(A^2)} = \sqrt{\lambda_0^2} = |\lambda_0| = \rho(A)。 \blacksquare$$

§ 3.1 矩阵范数

三、谱半径

- (1) 由于矩阵的2范数与谱半径有关，常称“2”范数为谱模。
- (2) 谱模（范数）是对称矩阵 A 特征值的上界。

§ 3.1 矩阵范数

定理 设 $\|\cdot\|$ 为矩阵的算子范数, 且 $\|A\| < 1$, 则 $I \pm A$ 为非奇异矩阵, 且有估计

$$\|(I \pm A)^{-1}\| \leq \frac{1}{1 - \|A\|}$$

证明 :

(1) 证 $I \pm A$ 为非奇异阵, 用反证法。

设 $I \pm A$ 为奇异阵, 则 $(I \pm A)x = 0$ 有非零解记为 x_0 ,
由 $\pm Ax_0 = x_0$ 得 $\|\pm Ax_0\| = \|x_0\|$, 而 $\|\pm Ax_0\| = \|Ax_0\|$,
于是,

$$\begin{aligned} \frac{\|Ax_0\|}{\|x_0\|} &= \frac{\|x_0\|}{\|x_0\|} = 1, \\ \Rightarrow \|A\| &= \max \frac{\|Ax\|}{\|x\|} \geq \frac{\|Ax_0\|}{\|x_0\|} = 1, \end{aligned}$$

这与假设矛盾。



定理 设 $\|\cdot\|$ 为矩阵的算子范数, 且 $\|A\| < 1$, 则 $I \pm A$ 为非奇异矩阵, 且有估计

$$\|(I \pm A)^{-1}\| \leq \frac{1}{1-\|A\|}$$

证明 : (2) 有 $(I - A)(I - A)^{-1} = I$,
 $\Rightarrow (I - A)^{-1} - A(I - A)^{-1} = I$
 $\Rightarrow (I - A)^{-1} = I + A(I - A)^{-1}$

$$\begin{aligned}\text{所以 } \|(I - A)^{-1}\| &= \|I + A(I - A)^{-1}\| \\ &\leq \|I\| + \|A(I - A)^{-1}\| \\ &\leq 1 + \|A\| \|(I - A)^{-1}\|, \\ \Rightarrow (1 - \|A\|)\|(I - A)^{-1}\| &\leq 1,\end{aligned}$$

$$\text{即 } \|(I - A)^{-1}\| \leq \frac{1}{1-\|A\|}.$$

$$\text{同理可得 } \|(I + A)^{-1}\| \leq \frac{1}{1-\|A\|}.$$

$$\|(I \pm A)^{-1}\| \leq \frac{1}{1-\|A\|}. \quad \blacksquare$$

